

23722291_CHTrungKien_M15

November 22, 2025

1 INFORMATION

1.1 Thông tin sinh viên

- Lớp: DHKHMT19A
- MSSV: 23722291
- Họ tên: Cao Huỳnh Trung Kiên
- Số máy: 15
- Tên file: 2372291_CHTrungKien_M15.ipynb

2 DESCRIPTION

Bối cảnh thực tế

Tập dữ liệu này được mô phỏng dựa trên hệ thống quản lý học tập (Learning Analytics System) của một trường đại học lớn tại Việt Nam. Mỗi bản ghi tương ứng với một sinh viên trong học kỳ gần nhất, thu thập từ các nguồn: hệ thống đào tạo, nền tảng học trực tuyến (E-learning), và khảo sát hành vi sinh viên. Mục tiêu là hỗ trợ nhà trường phân tích thói quen học tập, phát hiện nhóm sinh viên cần hỗ trợ và dự đoán kết quả học tập.

Chi tiết các thuộc tính

Thuộc tính	Kiểu	Mô tả	Nguồn / Ghi chú
StudentID	Integer	Mã định danh sinh viên duy nhất	Quản lý nội bộ
Age	Integer	Tuổi (18–30)	Hồ sơ nhập học
StudyHours	Float	Số giờ tự học mỗi tuần	Báo cáo sinh viên
AttendanceRate	Float (%)	Tỷ lệ dự lớp	Hệ thống điểm danh
AssignmentsCompleted	Float (%)	Tỷ lệ hoàn thành bài tập	LMS / Moodle
OnlineActivity	Float (giờ/tuần)	Số giờ học trực tuyến	Nhật ký E-learning
SleepHours	Float (giờ/ngày)	Giờ ngủ trung bình mỗi ngày	Khảo sát sinh viên
SocialActivity	Float (giờ/ngày)	Giờ giải trí / mạng xã hội	Khảo sát hành vi
MidtermScore	Float (0–100)	Điểm giữa kỳ	Khoa chuyên môn
FinalScore	Float (0–100)	Điểm cuối kỳ	Khoa chuyên môn
GPA	Float (0–4)	Điểm trung bình học kỳ	Quy đổi từ điểm thi
GradePoints	Float	$= \text{GPA} \times 25$	Thước đo quy đổi
PerformanceIndex	Float	$= (\text{Midterm} + \text{Final})/2$	Thước đo trung bình
Major	String	Ngành học (CS, IT, AI, DS, SE, CE)	Hồ sơ đào tạo
City	String	Cơ sở học (Hà Nội, TP.HCM, Đà Nẵng, Huế, Cần Thơ)	
Gender	String	Giới tính (Male/Female)	Hồ sơ sinh viên

3 IMPORT LIBRARIES

```
[25]: import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.compose import ColumnTransformer
from sklearn.preprocessing import OneHotEncoder, StandardScaler
from sklearn.cluster import KMeans
from sklearn.pipeline import Pipeline
from sklearn.metrics import silhouette_score
```

4 CODE HERE

4.1 Data Preparation And Preprocessing

```
[2]: # Đọc CSV
data = pd.read_csv('students_performance_practice.csv')
```

```
[3]: # Hiển thị thông tin cơ bản về dữ liệu
print(data.info())
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 10000 entries, 0 to 9999
Data columns (total 16 columns):
#   Column                Non-Null Count  Dtype
---  -
0   StudentID             10000 non-null  int64
1   Age                   10000 non-null  int64
2   StudyHours            9500 non-null   float64
3   AttendanceRate        9500 non-null   float64
4   AssignmentsCompleted  10000 non-null   float64
5   OnlineActivity        9500 non-null   float64
6   SleepHours            10000 non-null   float64
7   SocialActivity        10000 non-null   float64
8   MidtermScore          10000 non-null   float64
9   FinalScore            10000 non-null   float64
10  GPA                   10000 non-null   float64
11  GradePoints           10000 non-null   float64
12  PerformanceIndex      10000 non-null   float64
13  Major                 10000 non-null   object
14  City                  10000 non-null   object
15  Gender                10000 non-null   object
dtypes: float64(11), int64(2), object(3)
memory usage: 1.2+ MB
None
```

```
[4]: # Hiển thị 5 dòng đầu tiên của dữ liệu
data.head()
```

```
[4]:   StudentID  Age  StudyHours  AttendanceRate  AssignmentsCompleted  \
0          1   24         32.0           91.3              59.1
1          2   21         15.5           78.4              77.9
2          3   30         29.7           90.0              67.2
3          4   28         30.0           89.8              96.6
4          5   25          9.7           71.2              89.1

   OnlineActivity  SleepHours  SocialActivity  MidtermScore  FinalScore  GPA  \
0              7.7          5.8             2.9          71.2        92.8  3.67
1              6.3          6.2             0.2          59.8        82.2  2.94
```

2	6.2	8.1	2.2	65.5	93.9	3.61
3	4.5	6.1	0.0	61.5	87.0	3.74
4	5.9	7.6	3.1	58.0	76.4	3.20

	GradePoints	PerformanceIndex	Major	City	Gender
0	91.87	82.00	IT	Cần Thơ	Female
1	73.52	70.98	CE	Hà Nội	Male
2	90.34	79.68	SE	Hà Nội	Male
3	93.57	74.24	CS	Cần Thơ	Male
4	80.04	67.24	CS	Đà Nẵng	Male

```
[5]: # Loại bỏ các hàng bị thiếu dữ liệu của cột AttendanceRate
data = data.dropna(subset=['AttendanceRate'])
```

```
[6]: # Điền giá trị thiếu của cột StudyHours và OnlineActivity bằng giá trị trung vị
data.fillna({
    'StudyHours': data['StudyHours'].median(),
    'OnlineActivity': data['OnlineActivity'].median()
}, inplace=True)
```

```
[7]: # Tính ma trận tương quan
corr_matrix = data.select_dtypes(include=['int64', 'float64']).corr()

# In ra kết quả
corr_matrix
```

```
[7]:
```

	StudentID	Age	StudyHours	AttendanceRate	\
StudentID	1.000000	0.006326	0.013196	-0.019979	
Age	0.006326	1.000000	-0.000353	-0.003567	
StudyHours	0.013196	-0.000353	1.000000	0.005250	
AttendanceRate	-0.019979	-0.003567	0.005250	1.000000	
AssignmentsCompleted	-0.010720	-0.008419	0.022582	0.023410	
OnlineActivity	0.025020	-0.011135	-0.012352	0.016744	
SleepHours	0.009160	0.003319	-0.017759	-0.004509	
SocialActivity	0.018468	-0.007588	-0.008668	0.004180	
MidtermScore	0.002716	0.000330	0.606514	0.135726	
FinalScore	0.007551	-0.001475	0.729809	0.228572	
GPA	0.005515	-0.005660	0.680479	0.217695	
GradePoints	0.005518	-0.005718	0.680521	0.217754	
PerformanceIndex	0.006043	-0.000783	0.744312	0.207340	

	AssignmentsCompleted	OnlineActivity	SleepHours	\
StudentID	-0.010720	0.025020	0.009160	
Age	-0.008419	-0.011135	0.003319	
StudyHours	0.022582	-0.012352	-0.017759	
AttendanceRate	0.023410	0.016744	-0.004509	
AssignmentsCompleted	1.000000	0.008252	0.001310	

OnlineActivity	0.008252	1.000000	0.010760
SleepHours	0.001310	0.010760	1.000000
SocialActivity	0.002664	-0.002182	-0.012448
MidtermScore	0.022470	0.000184	0.002523
FinalScore	0.024752	-0.002012	-0.004030
GPA	0.022422	-0.000413	-0.005278
GradePoints	0.022391	-0.000513	-0.005228
PerformanceIndex	0.026177	-0.001173	-0.001302


	SocialActivity	MidtermScore	FinalScore	GPA \
StudentID	0.018468	0.002716	0.007551	0.005515
Age	-0.007588	0.000330	-0.001475	-0.005660
StudyHours	-0.008668	0.606514	0.729809	0.680479
AttendanceRate	0.004180	0.135726	0.228572	0.217695
AssignmentsCompleted	0.002664	0.022470	0.024752	0.022422
OnlineActivity	-0.002182	0.000184	-0.002012	-0.000413
SleepHours	-0.012448	0.002523	-0.004030	-0.005278
SocialActivity	1.000000	-0.003440	-0.033586	-0.027717
MidtermScore	-0.003440	1.000000	0.645867	0.608833
FinalScore	-0.033586	0.645867	1.000000	0.935892
GPA	-0.027717	0.608833	0.935892	1.000000
GradePoints	-0.027637	0.608867	0.935933	0.999986
PerformanceIndex	-0.022618	0.878829	0.931874	0.874199

	GradePoints	PerformanceIndex
StudentID	0.005518	0.006043
Age	-0.005718	-0.000783
StudyHours	0.680521	0.744312
AttendanceRate	0.217754	0.207340
AssignmentsCompleted	0.022391	0.026177
OnlineActivity	-0.000513	-0.001173
SleepHours	-0.005228	-0.001302
SocialActivity	-0.027637	-0.022618
MidtermScore	0.608867	0.878829
FinalScore	0.935933	0.931874
GPA	0.999986	0.874199
GradePoints	1.000000	0.874240
PerformanceIndex	0.874240	1.000000

```
[8]: plt.figure(figsize=(12, 8)) # kích thước hình
sns.heatmap(corr_matrix,
            annot=True, # hiển thị số tương quan
            cmap="coolwarm", # bảng màu dễ nhìn
            fmt=".2f", # format 2 chữ số thập phân
            linewidths=0.5) # đường ngăn ô

plt.title("Correlation Matrix", fontsize=16)
```

```
plt.show()
```



```
[9]: # Các cột có thuộc tính tuyến tính và không cần thiết
to_drop = ['GPA', 'GradePoints', 'PerformanceIndex', 'StudentID']

# Loại bỏ các cột này khỏi dữ liệu
data_cleaned = data.drop(columns=to_drop)
```

```
[18]: # Các cột dạng object
categorical_cols = data_cleaned.select_dtypes(include=['object']).columns.
    ↪ tolist()
```

```
[17]: # Các cột dạng numeric sau khi loại bỏ
numeric_cols = data_cleaned.select_dtypes(include=['int64', 'float64']).columns.
    ↪ tolist()
```

```
[19]: # Tiền xử lý dữ liệu
preprocess = ColumnTransformer(
    transformers=[
```

```

        ('num', StandardScaler(), numeric_cols),
        ('cat', OneHotEncoder(drop='first'), categorical_cols)
    ]
)

```

4.2 KMeans Clustering

```

[20]: # Xây dựng pipeline KMeans
pipe = Pipeline(steps=[
    ('prep', preprocess),
    ('kmeans', KMeans(n_clusters=4, random_state=42, n_init=10))
])

# Huấn luyện mô hình
pipe.fit(data_cleaned)

# Lấy nhãn cluster sau khi huấn luyện
labels = pipe.named_steps['kmeans'].labels_

# Gán nhãn cụm vào dữ liệu gốc
data_final = data_cleaned.copy()
data_final['Cluster'] = labels

```

```

[23]: # Thống kê số lượng sinh viên trong mỗi cụm
data_final['Cluster'].value_counts()

```

```

[23]: Cluster
2    2629
1    2574
0    2262
3    2035
Name: count, dtype: int64

```

4.3 Evaluate The Model

```

[27]: # Lấy dữ liệu đã được biến đổi sau tiền xử lý
X_transformed = pipe.named_steps['prep'].transform(data_cleaned)

# Tính silhouette score
sil_score = silhouette_score(X_transformed, labels)
print(f'Silhouette Score: {sil_score:.4f}')

```

Silhouette Score: 0.0740